TP2_NBA_Probabilistic_Analysis

October 4, 2025

1 TP 2 : Analyse Probabiliste des Joueurs NBA

1.1 Objectif

Analyser un dataset NBA et calculer des probabilités sur les tailles, âges et poids des joueurs.

1.2 Étapes principales :

1. Charger le dataset.
2. Explorer les données (EDA).
3. Ajuster des lois normales pour tailles/âges/poids.
4. Calculer des probabilités sur des intervalles donnés.
5. Étudier les écarts avec la loi normale (outliers).

[1]:
```
# Imports nécessaires
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from scipy.stats import norm
```

1.3 1. Chargement et exploration du dataset NBA

[2]:
```
# Charger le dataset NBA (adapter le chemin)
# Dataset Kaggle : https://www.kaggle.com/datasets/justinas/nba-players-data

df = pd.read_csv("nba_all_seasons.csv")

# Aperçu et statistiques descriptives
print(df.head())
print(df.describe())

# Exemple: statistiques sur la taille et l'âge
print(df['player_height'].describe())
print(df['age'].describe())
```

```
   Unnamed: 0       player_name team_abbreviation   age  player_height  \
0           0  Randy Livingston               HOU  22.0         193.04
1           1  Gaylon Nickerson               WAS  28.0         190.50
```

```
2           2      George Lynch               VAN  26.0         203.20
3           3    George McCloud               LAL  30.0         203.20
4           4      George Zidek               DEN  23.0         213.36

   player_weight               college country draft_year draft_round  …  \
0      94.800728       Louisiana State     USA       1996           2  …
1      86.182480  Northwestern Oklahoma     USA       1994           2  …
2     103.418976        North Carolina     USA       1993           1  …
3     102.058200         Florida State     USA       1989           1  …
4     119.748288                  UCLA     USA       1995           1  …

    pts  reb  ast  net_rating  oreb_pct  dreb_pct  usg_pct  ts_pct  ast_pct  \
0   3.9  1.5  2.4         0.3     0.042     0.071    0.169   0.487    0.248
1   3.8  1.3  0.3         8.9     0.030     0.111    0.174   0.497    0.043
2   8.3  6.4  1.9        -8.2     0.106     0.185    0.175   0.512    0.125
3  10.2  2.8  1.7        -2.7     0.027     0.111    0.206   0.527    0.125
4   2.8  1.7  0.3       -14.1     0.102     0.169    0.195   0.500    0.064

    season
0  1996-97
1  1996-97
2  1996-97
3  1996-97
4  1996-97

[5 rows x 22 columns]
         Unnamed: 0           age  player_height  player_weight            gp  \
count  12844.000000  12844.000000   12844.000000   12844.000000  12844.000000
mean    6421.500000     27.045313     200.555097     100.263279     51.154158
std     3707.887763      4.339211       9.111090      12.426628     25.084904
min        0.000000     18.000000     160.020000      60.327736      1.000000
25%     3210.750000     24.000000     193.040000      90.718400     31.000000
50%     6421.500000     26.000000     200.660000      99.790240     57.000000
75%     9632.250000     30.000000     208.280000     108.862080     73.000000
max    12843.000000     44.000000     231.140000     163.293120     85.000000

                pts           reb           ast    net_rating      oreb_pct  \
count  12844.000000  12844.000000  12844.000000  12844.000000  12844.000000
mean       8.212582      3.558486      1.824681     -2.226339      0.054073
std        6.016573      2.477885      1.800840     12.665124      0.043335
min        0.000000      0.000000      0.000000   -250.000000      0.000000
25%        3.600000      1.800000      0.600000     -6.400000      0.021000
50%        6.700000      3.000000      1.200000     -1.300000      0.040000
75%       11.500000      4.700000      2.400000      3.200000      0.083000
max       36.100000     16.300000     11.700000    300.000000      1.000000

           dreb_pct       usg_pct        ts_pct       ast_pct
count  12844.000000  12844.000000  12844.000000  12844.000000
```

```
mean       0.140646      0.184641      0.513138      0.131595
std        0.062513      0.053545      0.101724      0.094172
min        0.000000      0.000000      0.000000      0.000000
25%        0.096000      0.149000      0.482000      0.066000
50%        0.130500      0.181000      0.525000      0.103000
75%        0.179000      0.217000      0.563000      0.179000
max        1.000000      1.000000      1.500000      1.000000
count    12844.000000
mean       200.555097
std          9.111090
min        160.020000
25%        193.040000
50%        200.660000
75%        208.280000
max        231.140000
Name: player_height, dtype: float64
count    12844.000000
mean        27.045313
std          4.339211
min         18.000000
25%         24.000000
50%         26.000000
75%         30.000000
max         44.000000
Name: age, dtype: float64
```

1.4 2. Distribution des tailles des joueurs

[3]:
```
mean_height = df['player_height'].mean()
std_height = df['player_height'].std()

dist_height = norm(mean_height, std_height)

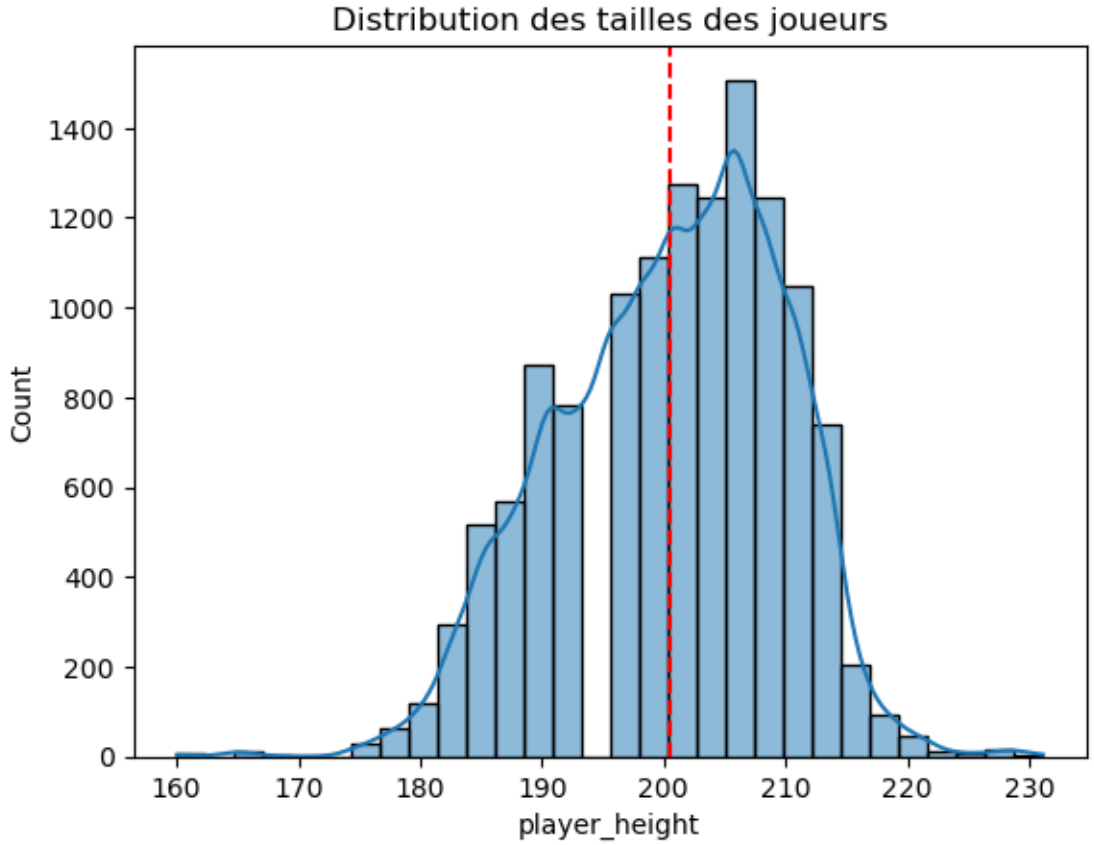
# Probabilité que la taille soit entre 200 et 210 cm
p_height = dist_height.cdf(210) - dist_height.cdf(200)
print(f"Probabilité qu'un joueur mesure entre 200cm et 210cm : {p_height:.4f}")

# Visualisation
sns.histplot(df['player_height'], bins=30, kde=True)
plt.axvline(mean_height, color='red', linestyle='--')
plt.title("Distribution des tailles des joueurs")
plt.show()
```

```
Probabilité qu'un joueur mesure entre 200cm et 210cm : 0.3743
```

```
C:\ProgramData\anaconda3\Lib\site-packages\seaborn\_oldcore.py:1119:
FutureWarning: use_inf_as_na option is deprecated and will be removed in a
future version. Convert inf values to NaN before operating instead.
```

```
with pd.option_context('mode.use_inf_as_na', True):
```



1.5 3. Distribution des âges des joueurs

[4]:
```
mean_age = df['age'].mean()
std_age = df['age'].std()

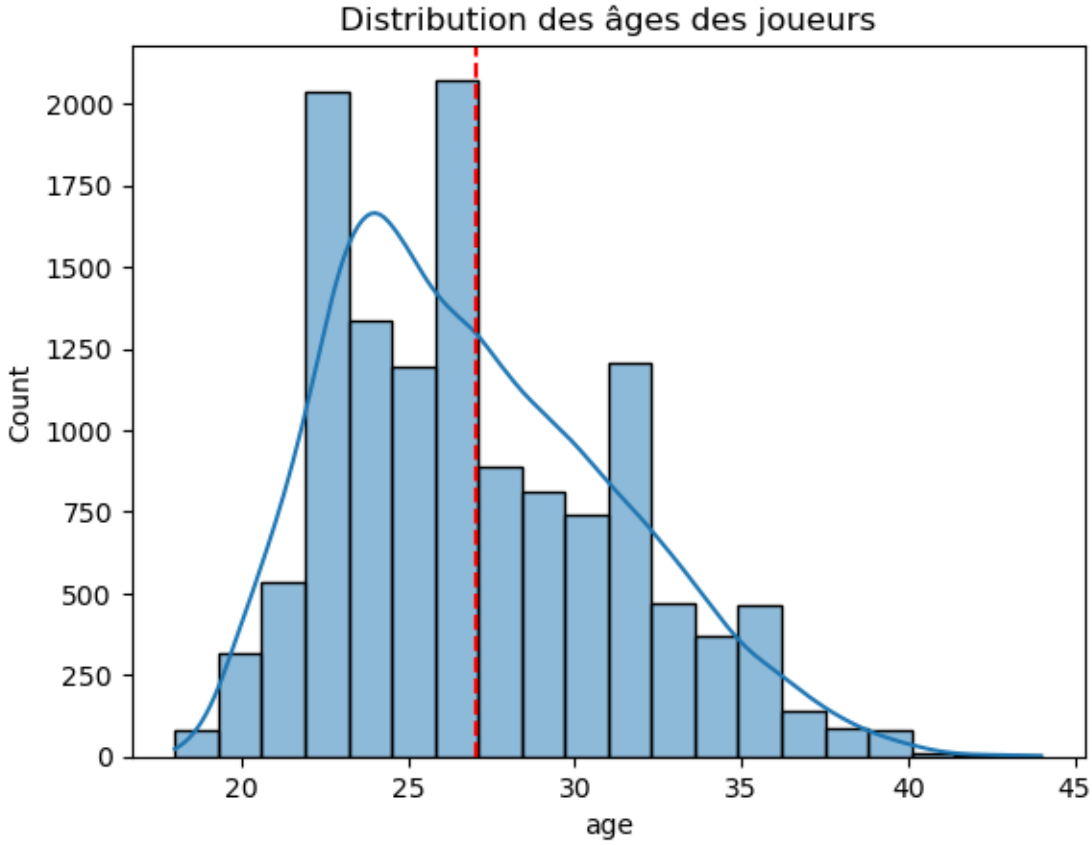
dist_age = norm(mean_age, std_age)
p_age = dist_age.cdf(27) - dist_age.cdf(20)
print(f"Probabilité qu'un joueur ait entre 20 et 27 ans : {p_age:.4f}")

sns.histplot(df['age'], bins=20, kde=True)
plt.axvline(mean_age, color='red', linestyle='--')
plt.title("Distribution des âges des joueurs")
plt.show()
```

```
Probabilité qu'un joueur ait entre 20 et 27 ans : 0.4436
```

```
C:\ProgramData\anaconda3\Lib\site-packages\seaborn\_oldcore.py:1119:
FutureWarning: use_inf_as_na option is deprecated and will be removed in a
future version. Convert inf values to NaN before operating instead.
```

```
with pd.option_context('mode.use_inf_as_na', True):
```

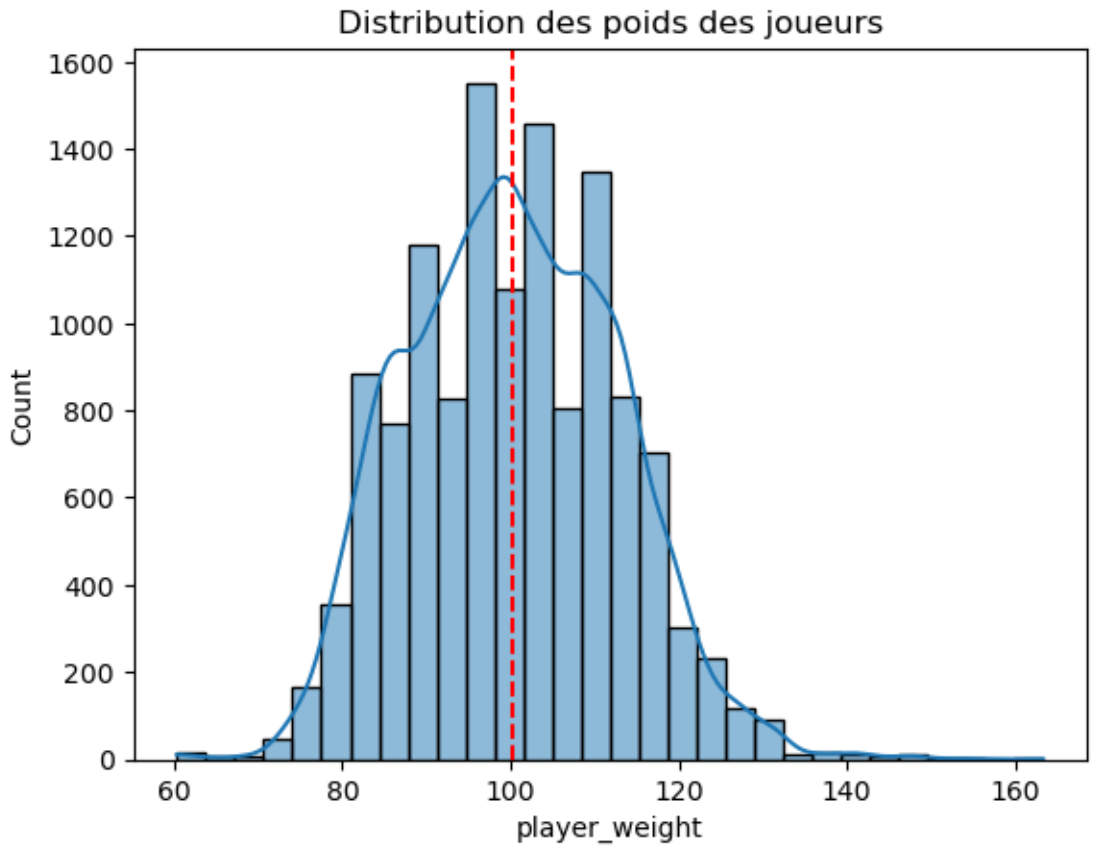


1.6 4. Distribution des poids des joueurs

[5]:
```
mean_weight = df['player_weight'].mean()
std_weight = df['player_weight'].std()

sns.histplot(df['player_weight'], bins=30, kde=True)
plt.axvline(mean_weight, color='red', linestyle='--')
plt.title("Distribution des poids des joueurs")
plt.show()
```

```
C:\ProgramData\anaconda3\Lib\site-packages\seaborn\_oldcore.py:1119:
FutureWarning: use_inf_as_na option is deprecated and will be removed in a
future version. Convert inf values to NaN before operating instead.
  with pd.option_context('mode.use_inf_as_na', True):
```



1.7 5. Analyse et interprétation

- Vérifiez si la somme des probabilités 1 (total probability rule).
- Observez les écarts par rapport à la normale (outliers possibles).
- Ajustez l'écart-type (par ex. std * 0.8) et recalculer les probabilités.

1.8 6. Travail demandé – Analyse et interprétation

Dans cette partie, vous devez produire une **analyse écrite en Markdown** de vos résultats. Utilisez vos propres mots pour expliquer et commenter ce que vous observez dans le TP.

1.8.1 Points attendus :

1. **Statistiques descriptives**
   - Que révèlent la moyenne, l'écart-type, les valeurs min/max sur la taille, l'âge et le poids des joueurs NBA ?
   - Comparez ces statistiques avec vos intuitions sur des joueurs professionnels.
2. **Distributions et visualisations**

- Interprétez les histogrammes et les courbes de densité.

- Les distributions semblent-elles proches de la loi normale ? Pourquoi ?

3. **Calculs de probabilités**
   - Expliquez la signification des probabilités calculées (ex. : probabilité qu'un joueur mesure entre
   - Expliquer la difference entre la CDF et PDF ?0 et 210 cm).

   - Discutez de la pertinence de ces résultats par rapport à la réalité.
4. **Écarts et valeurs aberrantes**
   - Discutez des éventuelles valeurs atypiques (joueurs très grands/petits, très lourds/légers).

   - Qu'est-ce que cela implique pour l'ajustement d'une loi normale ?
5. **Conclusion personnelle**
   - Que retenez-vous de cette analyse ?

   - Quelles améliorations ou extensions pourriez-vous proposer (autres variables, tests d'hypothèses, comparaisonment l'exécution du code.

NB : L'objectif est de démontrer votre **capacité d'analyse critique**, pas seulement l'exécution du code.

[ ]: